SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni diplomski studij Umjetna inteligencija i robotika

Jednostavna sinteza ultrazvučne B-mode slike konvolucijom

Seminarski rad

Marta Dasović

Osijek, 2026.

Sadržaj

1 UVOD 1
2 PREGLED PODRUČJA I PROBLEMATIKE 2
3 METODOLOGIJA I IMPLEMENTACIJA 4
3.1 Opis podataka 4
3.2 Mapa akustične impedancije 7
3.3 PSF 8
3.4 Transformacije 10
4 REZULTATI I USPOREDBA 12
5 ZAKLJUČAK 15

1 UVOD

Ultrazvuk je jedna od najpristupačnijih i najčešće korištenih medicinskih metoda. Temelji se na širenju valova kroz biološko tkivo i refleksijama signala koje nastaju na granicama između tkiva različitih akustičnih svojstava. Kod standardne B-mode (brightness mode) slike, amplituda reflektiranog signala prikazuje se kao svjetlina piksela, čime se dobiva dvodimenzionalni prikaz unutarnjih struktura. Jednostavna sinteza B-mode slike konvolucijom predstavlja koristan pristup za razumijevanje utjecaja parametara sustava, frekvencije sonde i prostorne rezolucije. Prednost B-mode prikaza leži u relativno jednostavnoj interpretaciji slike, visokoj vremenskoj rezoluciji te dinamičkoj vizualizaciji anatomskih struktura u stvarnom vremenu.

U ovom radu koristi se trodimenzionalni CT volumen s pripadajućim segmentacijama tkiva. CT slike široko se primjenjuju u dijagnosticiranju stanja unutarnjih organa i predstavljaju 3D skenove rekonstruirane u niz 2D presjeka tijela. Cilj je iz 2D presjeka tkiva generirati model ultrazvučne slike kao konvoluciju akustične refleksije pomoću funkcije širenja točke (*engl.* PSF - Point spread function). Rad opisuje sve korake implementacije koji uključuju stvaranje mape akustičnih prigušenja, konvoluciju s PSF-om te primjenu standardnih transformacija za dobivanje B-mode slike (Hilbert transformacija, log kompresija). Sintetizirane ultrazvučne slike bit će uspoređene sa stvarnim snimkama radi procjene realističnosti modela. Također, bit će opisan korišteni skup podataka, kao i osnovni koncepti i metode.

2 PREGLED PODRUČJA I PROBLEMATIKE

Ultrazvuk je u medicinskoj dijagnostici kontinuirano napredovao tijekom nekoliko desetljeća, od jednostavnih A-mode i statičnih B-mode prikaza do suvremenih sustava za real-time vizualizaciju. Danas ultrazvuk omogućuje prikaz pokretnih struktura, mjerenje protoka krvi i procjenu svojstava tkiva, što ga čini prvom metodom izbora u mnogim dijagnostičkim postupcima. [1]

Postoji nekoliko pristupa simulaciji ultrazvučnih slika, a jedan od najčešće korištenih je konvolucijski model baziran na point spread funkciji. Dva osnovna pristupa simulaciji ultrazvuka su: fizikalni pulse-echo model temeljen na linearnoj akustici i konvolucijski pristup, odnosno pristup temeljen na PSF. U pulse-echo pristupu simulacija ultrazvuka se provodi modeliranjem emitiranog ultrazvučnog polja i pulse-echo odgovora tkiva primjenom linearne akustike. Tkiva se modeliraju kao prostorna raspodjela točkastih scatterera, dok se ultrazvučna slika generira simulacijom propagacije ultrazvučnog vala kroz medij te analizom povratnog signala. Ovakav pristup daje vrlo precizne slike, ali je računalno vrlo zahtjevan. Primjerice, simulacija slike dimenzija 64×64 s 200.000 scatterera može trajati više od tri sata. S druge strane, pojednostavljeni konvolucijski pristup generira ultrazvučnu sliku kao konvoluciju mape scattera s modelom ultrazvučnog polja (PSF) [2]. Ovaj pristup opisali su i predložili Bamber i Dickinson [3] te se njihov rad smatra temeljnim za konvolucijski pristup simulaciji B-mode ultrazvuka. Glavna prednost takvog pristupa je što omogućuje značajno bržu simulaciju. Dillenseger i suradnici [2] usvajaju i proširuju konvolucijski model Bambera i Dickinsona. Autori zadržavaju linearnu formulaciju temeljenu na PSF konvoluciji, ali model dodatno prilagođavaju stvarnim geometrijama ultrazvučnih sondi. Uz navedene pulse-echo i konvolucijske modele, literatura opisuje i alternativne pristupe simulaciji ultrazvuka [4]. Među njima se ističu metode temeljene na valovima (*engl.* Wave-based methods) koje simuliraju širenje ultrazvuka numeričkim rješavanjem potpune jednadžbe akustičnog vala. Nadalje, metode temeljne na zrakama (*engl.* Ray-based methods) primjenjuju principe geometrijske akustike te prate zrake kroz granice tkiva kako bi simulirale refleksiju ili lom. U posljednjem desetljeću značajan napredak u simulaciji B-mode ultrazvuka ostvaren je primjenom metoda umjetne inteligencije, osobito dubokog učenja. AI-based pristupi razlikuju se od klasičnih fizikalnih modela jer ne modeliraju eksplicitno propagaciju vala, već uče preslikavanje između ulaznih podataka i ultrazvučne slike.

Prikazani pregled ističe napredak u tehnologijama ultrazvučne simulacije te raznolikost pristupa razvijenih s ciljem što realističnijeg modeliranja slike. Posebno je važno naglasiti da je mogućnost real-time prikaza jedna od ključnih prednosti B-mode ultrazvuka. Budući razvoj usmjeren je prema hibridnim pristupima koji integriraju fizikalne modele, strojno učenje i diferencijabilne simulacijske okvire.

3 METODOLOGIJA I IMPLEMENTACIJA

Konvolucijski pristup simulaciji ultrazvučne B-mode slike temelji se na modelu u kojem se raspodjela reflektirajućih struktura u tkivu konvoluira s funkcijom širenja točke (PSF). U usporedbi s ostalim metodama, konvolucijski model nudi optimalan kompromis između računalne efikasnosti, vizualne realističnosti i brzine izvođenja. Zbog svoje efikasnosti i jednostavnosti odabran je kao temelj za simulaciju ultrazvučne slike u ovom radu. Proces sinteze ultrazvučne B-mode slike sastoji se od tri osnovna koraka koje prati i sama programska implementacija:

1. Konstrukcija mape akustične impedancije.
2. Generiranje radiofrekvencijske (RF) slike konvolucijom mape akustičnih prigušenja s modeliranom PSF funkcijom.
3. Primjena transformacija za generiranje konačne B-mode slike: Hilbert transformacija i logaritamska kompresija.

U nastavku poglavlja, detaljno su opisani navedeni koraci implementacije.

3.1 Opis podataka

Za rješavanje ovog zadatka korišten je javno dostupni medicinski skup podataka objavljen na platformi Zenodo. Skup podataka objavljen je 2023. godine te sadrži 102 anatomske strukture različitih dijelova ljudskog tijela. Temelji se na CT snimkama ljudskog tijela te je podskup projekta TotalSegmentator. Podatci su pohranjeni u NIfTI (*engl.* Neuroimaging Informatics Technology Initiative) formatu koji predstavlja standardni način pohrane u medicinskoj obradi slika. NIfTI datoteka sadrži 3D ili 4D matricu voxela, odnosno numeričke vrijednosti intenziteta te zaglavlje koje sadrži informacije o dimenziji, veličini voxela, orijentaciji u prostoru te tip podataka. Prednost takvog formata je što omogućuje očuvanje stvarne prostorne geometrije snimke [5]. Osim podataka koji su pohranjeni u NIfTI formatu (.nii.gz formatu), podatci uključuju automatski generirane segmentacije anatomskih struktura te detaljnu anatomsku klasifikaciju. Segmentacije su grupirane u nekoliko osnovnih kategorija relevantnih za modeliranje: masno tkivo, meko tkivo, mišići, organi i kosti. U medicinskoj dijagnostici, kao što su CT (računalna tomografija) i MRI (magnetska rezonanca), postoji nekoliko anatomskih ravnina po kojima se izvršavaju anatomski presjeci: sagitalni, koronalni i aksijalni.

- Sagitalni presjek dijeli tijelo uzdužno na lijevu i desnu polovicu, a odgovara presjeku po x osi slike.
- Koronalni (frontalni) presjek predstavlja vertikalnu ravninu koja dijeli tijelo na prednji i stražnji dio te odgovara presjeku po y osi.
- Aksijalni (transverzalni) presjek dijeli tijelo na gornji i donji dio. Predstavlja horizontalnu ravninu te odgovara presjeku po z osi. Ovakav tip presjeka korišten je za sintezu B-mode slike. [6]

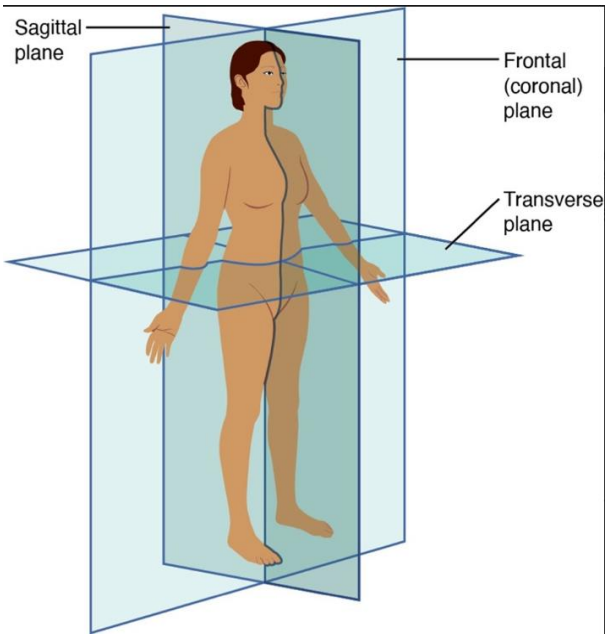

Sl. 3.1 Anatomske ravnine ljudskog tijela [6]

Slika 3.1 prikazuje sve tri anatomske ravnine tijela. Za potrebe ovog rada korišten je aksijalni presjek volumena. Slika 3.2 prikazuje segmentaciju tkiva aksijalnog presjeka volumena s pripadajućom legendom koja označava klasificirane segmente, a radi lakšeg razumijevanja prikazana je i segmentacija tkiva koronalnog presjeka istog volumena. Aksijalni presjek izveden je na nižem dijelu slike, kako bi se presjeklo abdominalno područje koje će se promatrati tokom ovog rada.

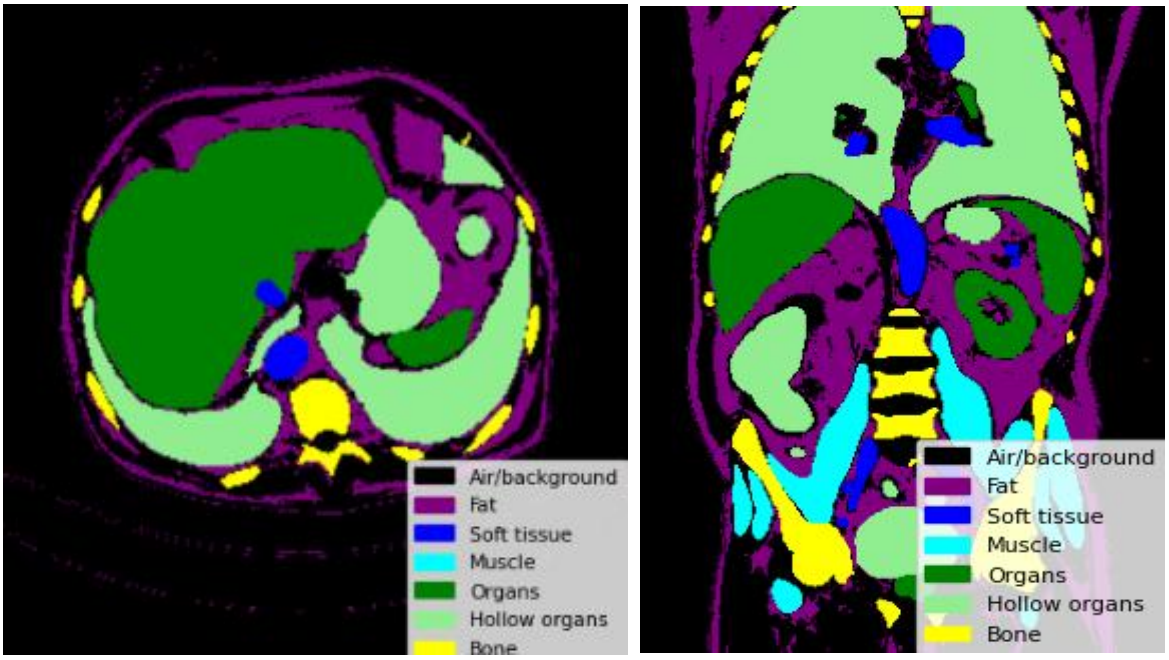

Sl. 3.2 A – aksijalni presjek segmentacije tkiva, **B** – koronalni presjek segmentacije tkiva

Radi bolje interpretacije anatomskih struktura, na aksijalnom presjeku CT snimke dodatno su označeni glavni organi koji su prikazani na slici 3.3.

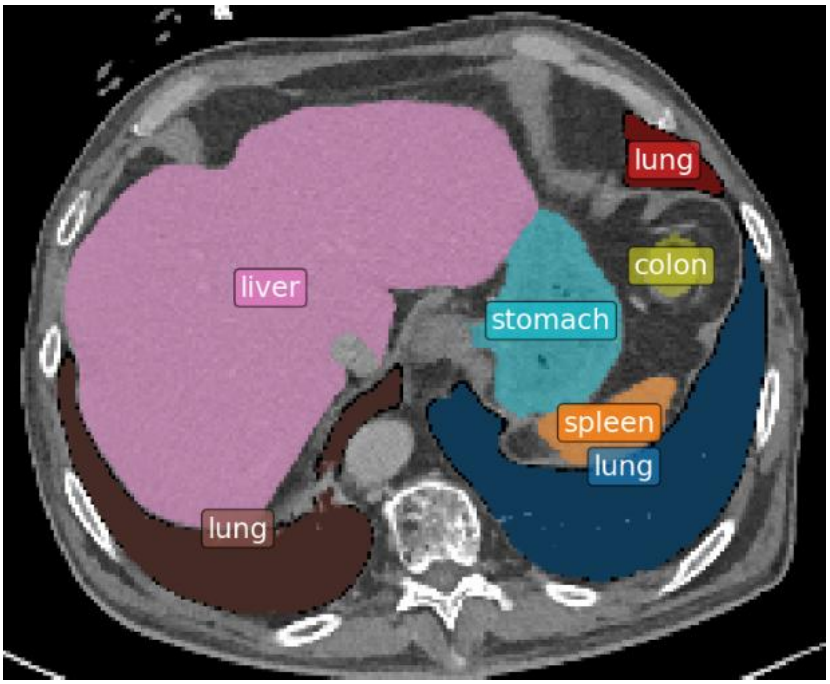

Sl. 3.3 Prikaz organa na aksijalnom presjeku tkiva

3.2 Mapa akustične impedancije

Akustična impedancija temeljna je fizikalna veličina u ultrazvučnoj dijagnostici. Definira se kao omjer tlaka i brzine čestica sredstva kroz koje zvuk prolazi, a određena je gustoćom i krutošću tkiva izrazom

$$z = \rho c \tag{5-1}$$

gdje je ρ gustoća, a c brzina zvuka u tkivu. [1]

Vrijednosti akustične impedancije za određena tkiva prikazane su u tablici 3.1.

Tab. 3.1. Vrijednosti akustične impedancije za određena tkiva [2]:

Tkivo	$z(10^6 kgm^{-2}s^{-1})$
Mast	1.35
Meko tkivo	1.65
Organi	1.67
Mišići	1.70
Kosti	5.0

U ovom radu, akustična impedancija koristi se za izgradnju mape akustične impedancije. To je dvodimenzionalna matrica čiji svaki piksel odgovara impedanciji tkiva koje se u tom pikselu nalazi, određenoj na temelju klasifikacije tkiva iz CT segmentacije. Svakom segmentiranom tipu tkiva pridružena je konstantna vrijednost impedancije prema Tablici 3.1. Na temelju tih vrijednosti formira se mapa akustičnog prigušenja u kojoj je svako tkivo prikazano proporcionalno svojoj sposobnosti prigušenja zvučnih valova, pri čemu se voda i zrak prikazuju kao područja vrlo niskih vrijednosti (tamni tonovi), masno tkivo srednjih vrijednosti (sivi tonovi), dok koštano tkivo odgovara visokim vrijednostima (svijetli tonovi). Mapa akustičnog prigušenja prema parametrima iz tablice prikazana je na slici 3.4. Zatim je na generiranu mapu dodan Rayleighov šum kako bi se simulirala prirodna nehomogenost tkiva, karakteristična za stvarne B-mode ultrazvučne slike. Svakom tkivu je dodijeljen šum različite gustoće na temelju njihovih svojstava

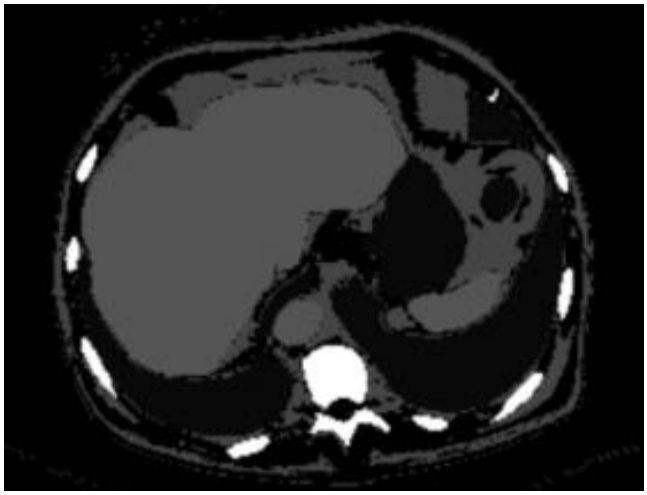

Sl. 3.4 Mapa akustične impedancije tkiva

Budući da akustična impedancija tkiva varira u širokom rasponu - od 0.0004 za zrak do 5.00 za kost, takav dinamički raspon u simulaciji uzrokuje numeričke probleme pri računanju drugog derivata mape impedancije. Rubovi zbog prevelikog kontrasta dominiraju, dok relevantni prijelazi između mekih tkiva postaju zanemarivi, što rezultira bijelim masnim tkivom i tamnijim organima. Kako bi se to ublažilo impedancija pozadine povećana je s 0.0004 na 1.15, a impedancija kosti smanjena je s 5.0 na 2.5 čime je dinamički raspon smanjen a simulacija ultrazvučne slike poboljšana.

3.3 PSF

Budući da niti jedan realni sustav ne može savršeno prikazati točku dolazi do zamućenja, umjesto originalne točke na slici se ta točka razmazuje. Funkcija širenja točke (engl. Point Spread Function, PSF) matematički opisuje oblik i veličinu tog zamućenja. Navedena funkcija je trodimenzionalna i poznata kao rezolucijska ćelija sustava, a nastaje zbog difrakcijskog širenja ultrazvučnog signala. Aksijalna rezolucija, u smjeru širenja vala, otprilike je jednaka polovici duljine pulsa i relativno je konstantna s dubinom, dok je lateralna rezolucija jednaka širini ultrazvučnog zraka i optimalna u fokalnom području pretvarača. [7]

Za potrebe rješavanja ovoga problema korišten je 2D PSF model Bambera i Dickinsona prilagođen za aksijalni presjek CT volumena. PSF opisan je kao sinusni val moduliran Gaussovom ovojnicom [2]:

$$H(x,y) = e^{-\frac{1}{2}\left(\frac{x^2}{\sigma_{ax}^2} + \frac{y^2}{\sigma_{lat}^2}\right)} \cos(2\pi f x) \tag{5-2}$$

pri čemu su:

σ_{ax} – duljina ultrazvučnog pulsa

σ_{lat} - širina ultrazvučnog pulsa

f - prostorna frekvencija ultrazvučnog pulsa

Oblik PSF-a određen je karakteristikama ultrazvučnog signala. Valovi ultrazvuka se od svake točke odbijaju kružnim valom natrag, tako da se svaka točka razvuče lijevo-desno od sonde po kružnici. Rezultirajući PSF prikazan je na slici 3.5.

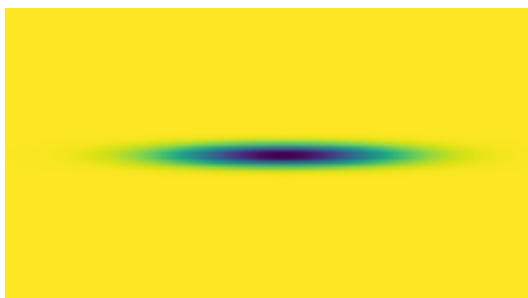

Sl. 3.5 PSF

U konačnici, radiofrekvencijska (RF) slika dobivena je kao konvolucija funkcije tkivne ehogenosti s funkcijom širenja točke. RF slika dobivena je izrazom [2]:

$$I(x,y) = (H * T)(x,y) \tag{5-3}$$

Pri čemu je T(x,y) pojednostavljena funkcija tkivne ehogenosti definirana kao drugi derivat mape akustične impedancije Z duž aksijalne osi širenja vala [2]:

$$T(x,y) = \frac{\partial^2 Z}{\partial x^2} \tag{5-4}$$

3.4 Transformacije

Nakon što je generirana radiofrekvencijska slika potrebno je primijeniti niz transformacija kako bi se dobila konačna B-mode slika pogodna za vizualizaciju i interpretaciju. RF signal sadrži visokofrekventne oscilacije koje nisu izravno vidljive niti korisne u prikazu, stoga se primjenjuju dva ključna koraka obrade signala. Prvi korak je detekcija ovojnice Hilbertovom transformacijom, a nakon toga primjenjuje se logaritamska kompresija. Navedeni koraci rezultiraju konačnom B-mode ultrazvučnom slikom.

Hilbertova transformacija matematička je funkcija koja ulazni signal pomiče za 90 stupnjeva u fazi, neovisno o frekvenciji signala. Time se vrhovi oscilacija u RF podatcima pomiču vremenski prema dolovima signala. Kombinirani originalni i transformirani signal međusobno popunjavaju oscilacije jedan drugoga, čime se procjenjuje magnituda ovojnice. Rezultat je dobra aproksimacija energije pulsa koja smanjuje oscilacija uz maksimiziranje detalja slike. Primjenom Hilbertove transformacije na RF signal dobiva se analitički signal čija apsolutna vrijednost predstavlja ovojnicu signala. [8] Ovojnica se dobiva izrazom [2]:

$$I_B(x,y) = |I(x,y) + j \cdot Hilbert(I(x,y))| \tag{5-5}$$

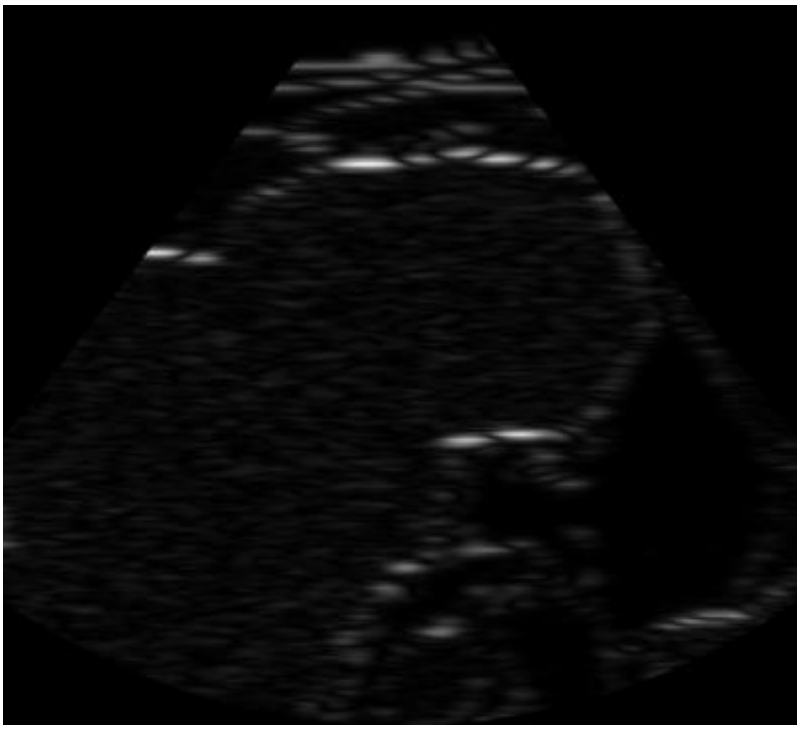

Sl. 3.6 Hilbert ovojnica

Slika 3.6 prikazuje ovojnicu dobivenu primjenom Hilbertove transformacije na RF sliku, pri čemu je prikazan samo relevantni isječak aksijalnog presjeka CT volumena. Svjetlija područja odgovaraju granicama tkiva gdje su refleksije ultrazvučnog vala najjače, dok tamna područja odgovaraju homogenim regijama s malim amplitudama ovojnice.

Logaritamska kompresija završni je korak u generiranju B-mode slike. Dinamički raspon detektiranih B-mode signala može premašiti 150 dB, što je previše za smisleni prikaz na monitoru čiji je dinamički raspon ograničen na oko 30 dB. Stoga se u B-mode prikazu primjenjuje logaritamska kompresija, nelinearna tehnika kompresije signala. Logaritamskom kompresijom slabi signali mogu se jasno prikazati zajedno s jakim signalima. U programskoj implementaciji odabran je dinamički raspon od 40 dB, stoga se signal ograničava na taj raspon i normalizira na interval [0, 1]. [9]

4 REZULTATI I USPOREDBA

U ovom poglavlju prikazani su rezultati simulacije B-mode ultrazvučne slike dobivene prethodno opisanim koracima. Konačna B-mode slika prikazuje relevantno abdominalno područje koje se uspoređuje s referentnim radom [2]. Analiziran je utjecaj frekvencije pulsa te broja elemenata sonde na prostornu rezoluciju i kvalitetu simuliranih slika.

Slika 4.1 prikazuje utjecaja frekvencije pulsa na simuliranu ultrazvučnu B-model sliku. Slike prikazuju simulaciju na frekvencijama impulsa od 1 MHz i 5 MHz. Iz priloženog se može zaključiti da se povećanjem frekvencije impulsa povećava prostorna rezolucija slike. U ovoj implementaciji nije uzeta u obzir apsorpcijska atenuacija signala u tkivu, koja u stvarnim sustavima progresivno slabi signal s dubinom i time ograničava primjenu visokih frekvencija za prikaz dubljih struktura.

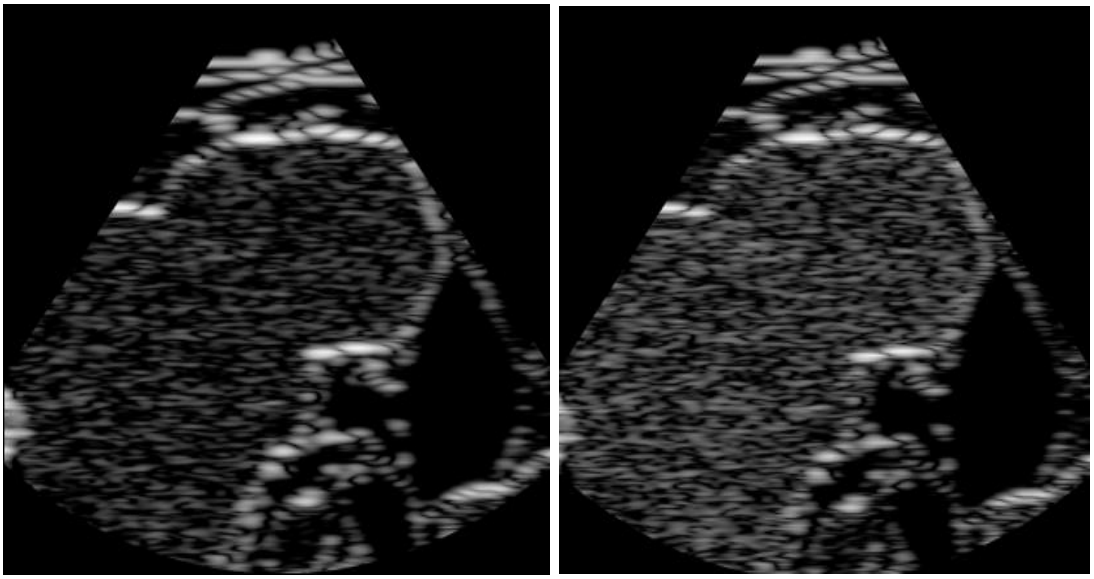

Sl. 4.1 Ultrazvučna B-mode simulacija s frekvencijom pulsa 1MHz (lijevo) i 5MHz (desno)

Slika 4.2 prikazuje utjecaja broja elemenata sonde na simuliranu ultrazvučnu B-model sliku. Simulacija je provedena za sonde s 64 i 128 elemenata pri jednakoj frekvenciji pulsa od 3.5 MHz. Broj elemenata izravno utječe na lateralnu rezoluciju slike, odnosno veći broj elemenata omogućuje uži ultrazvučni zrak i time oštriji prikaz struktura u lateralnom smjeru. Razlika u lateralnoj rezoluciji posebno je vidljiva na rubovima organa i manjim anatomskim strukturama poput krvnih žila.

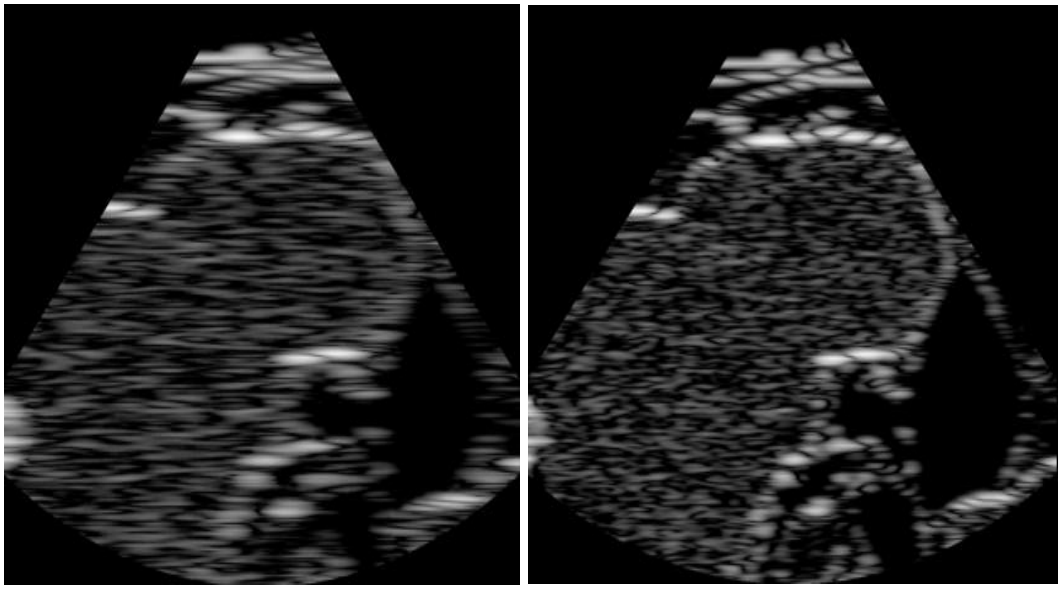

Sl. 4.2 Ultrazvučna B-mode simulacija s brojem elemenata sonde 64 (lijevo) i 128 (desno)

Slika 4.3 prikazuje usporedbu dobivenog simuliranog modela (dolje lijevo) sa dobivenim simuliranim modelom referentnog rada (dolje desno) i stvarnom B-mode ultrazvučnom slikom (gore). Simulacije koriste frekvenciju pulsa 3.5 MHz te 128 elemenata sonde. Frekvencija od 3.5 MHz predstavlja kompromis između rezolucije i prodiranja u tkivo, što odgovara standardnoj kliničkoj praksi.

Glavna razlika između simuliranog B-mode modela dobivenog u ovom radu i referentnog simuliranog modela je da ono koristi polarnu transformaciju koja bolje odgovara geometriji kružne sonde, dok dobivena simulacija koristi Kartezijev koordinatni sustav s naknadnom primjenom sektorske maske. Dobivena simulacija ima izraženije prijelaze između struktura tkiva te manju gustoću šuma. Unatoč tome, obje simulacije pokazuju prepoznatljiv sektorski oblik sonde te vidljiva sučelja između tkiva kao svjetlije linije na rubovima organa.

Razlika između stvarne ultrazvučne B-mode slike i simuliranog modela ovoga rada je što stvarna slika pokazuje bogatiju zrnastu teksturu koja naglašuje mikroinhomogenosti tkiva koje nisu u potpunosti modelirane u ovoj implementaciji. Unatoč navedenim razlikama, osnovna anatomska struktura i raspored tkiva prepoznatljivi su u simuliranoj slici, što potvrđuje valjanost primijenjenog konvolucijskog pristupa.

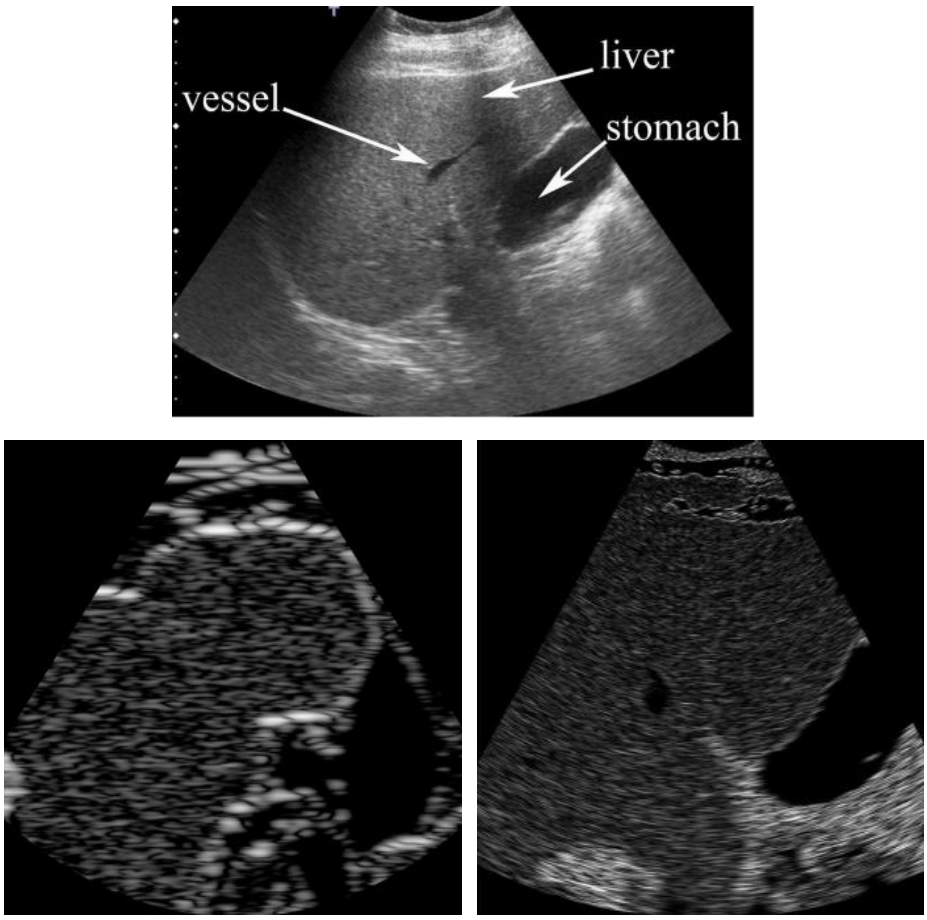

Sl. 4.3 Usporedba stvarne ultrazvučne B-mode slike (1), simulirane slike dobivene u ovom radu (2) i referentne simulirane slike (3)

5 ZAKLJUČAK

U ovom radu prikazan je konvolucijski pristup sintezi ultrazvučne B-mode slike temeljen na CT podacima i modeliranju funkcije širenja točke. Implementirani model omogućio je generiranje simuliranih ultrazvučnih slika koje uspješno prikazuju osnovne karakteristike stvarnih B-mode prikaza.

Proces sinteze ultrazvučne slike realiziran je kroz tri ključna koraka. Prvo je konstruirana mapa akustične impedancije na temelju segmentiranih CT podataka, čime je definiran prostorni raspored fizikalnih svojstava tkiva. U drugom koraku generirana je radiofrekvencijska slika primjenom konvolucije mape akustičnih svojstava s modeliranom funkcijom širenja točke. Konačno, primjenom Hilbertove transformacije i logaritamske kompresije dobivena je ultrazvučna B-mode slika pogodna za vizualizaciju i interpretaciju.

Analizom rezultata pokazano je kako ključni parametri sustava, poput frekvencije ultrazvučnog pulsa i broja elemenata sonde, značajno utječu na kvalitetu i rezoluciju dobivene slike. Dobiveni model ima određena ograničenja, poput pojednostavljenog prikaza tkiva i izostanka nekih fizikalnih fenomena, primjerice složenijih interakcija ultrazvučnih valova s tkivom. Unatoč tome uspješno prikazuje glavne anatomske strukture te pruža dobar prikaz različitih tipova tkiva. Budući rad može biti usmjeren na unapređenje modela uključivanjem naprednijih fizikalnih efekata, korištenjem polarne geometrije sonde te primjenom metoda strojnog učenja za dodatno poboljšanje realističnosti simulacije.

LITERATURA

[1] Peter. Hoskins, Kevin. Martin, and Abigail. Thrush, *Diagnostic ultrasound : physics and equipment*. Cambridge University Press, 2010.

[2] J.-L. Dillenseger, S. Laguitton, and E. Delabrousse, “Fast simulation of ultrasound images from a CT volume. Fast Simulation of Ultrasound Images from a CT volume,” *Comput. Biol. Med.*, vol. 39, no. 2, pp. 180–186, 2009, doi: 10.1016/j.compbiomed.2008.12.009ï.

[3]. C. Bamber and R. J. Dickinson, “Ultrasonic B-scanning: a computer simulation,” *Phys Med Biol*, 1980.

[4] C. M. Solano-Cordero, N. Encina-Baranda, M. Pérez-Liva, and J. L. Herraiz, “Recent Advances in B-Mode Ultrasound Simulators,” Dec. 01, 2025, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/app152312535.

[5] “THE NIFTI-1 DATA FORMAT.”

[6] J. G. Betts, *Anatomy and Physiology 2e.*, 2nd ed. 2022.

[7] Thomas L. Szabo, “Diagnostic Ultrasound Imaging: Inside Out (2nd ed.),” *Academic Press* , 2014.

[8] Kenneth MacCallum, “Ultrasound Signal Processing Techniques Explained,” StarFish Medical.

[9] Y. Lee, J. Kang, and Y. Yoo, “Automatic dynamic range adjustment for ultrasound B-mode imaging,” *Ultrasonics*, vol. 56, pp. 435–443, Feb. 2015, doi: 10.1016/j.ultras.2014.09.012.

PRILOZI

Cjelokupna programska implementacija nalazi se na javno dostupnom GitHub repozitoriju: https://github.com/dasmarta/bmode_ultrasound_synth